



CAHIER DES CHARGES — Projet Vital Ka × HWAT

Écosystème de santé panafricain alimenté par l'IA harmonique

Version	2.0
Date	1er août 2026
Statut	Spécification finale — implémentation en cours
Auteur	Vital Ka — Équipe HarmoniqLLM

Table des matières

- [1. Présentation générale](#)
- [2. Contexte et objectifs](#)
- [3. Architecture globale](#)
- [4. Spécifications fonctionnelles](#)
- [5. Spécifications techniques](#)
- [6. API — Contrats d'interface](#)
- [7. Données](#)
- [8. Sécurité et conformité](#)
- [9. Performance](#)
- [10. Déploiement](#)
- [11. Planification et budget](#)
- [12. Risques et mitigations](#)
- [13. Critères de validation](#)
- [14. Annexes](#)

1. Présentation générale

1.1 Le projet en une phrase

Vital Ka est un écosystème de santé panafricain (4 applications mobiles + IA embarquée) dont le cerveau est **HWAT** (Harmonic Wavelet Attention Transformer), une architecture d'intelligence artificielle fondée sur la physique ondulatoire : les mots sont des ondes complexes $\psi = A \cdot e^{i\phi}$, et l'attention est une interférence de phase $\cos(\Delta\phi)$.

1.2 Les trois piliers

Pilier	Description	Statut
IA harmonique	HWAT + 15 hologrammes médicaux spécialisés	✅ Fonctionnel
Santé connectée	4 apps : Patient, Médecin, Pharmacien, Solidarité	✅ Fonctionnel
Économie médicale	Unités Médicales (UM) : 1 UM = 1 EUR = 655 CFA	✅ Fonctionnel

1.3 Les 13 fonctionnalités livrées (récapitulatif)

```
mindmap
  root((Vital Ka × HWAT))
    IA Harmonique
      HWAT (attention de phase)
      15 hologrammes médicaux
      Routeur spectral
      Phrasé naturel
      Anti-hallucination
      Enrichissement 158 faits
    Applications
      Patient (dossier + wallet)
      Médecin (diagnostic + honoraires)
      Pharmacien (caisse + interactions)
      Solidarité (diaspora → UM)
    API (7 endpoints)
      Diagnose
      Prescribe
      Interactions
      Explain
      Hologram/query
      Health / Model-info
    Android Capacitor
      Routeur offline JS
      Bundle 62K faits embarqué
      Portefeuille santé UM
    Entraînement 125M
      Corpus médical 63.7M chars
      Tokenizer BPE 50K
      Kaggle GPU (en cours)
    Partenariat MTN
      Dossier technique
      Compression massive
```

2. Contexte et objectifs

2.1 Problème

- **60% des consultations en Afrique subsaharienne** sont informelles (pas de dossier médical)
- Les LLM classiques **hallucinent** (3-10%) — inacceptable en santé

- L'IA nécessite des **GPU massifs** inexistants sur le continent
- Les paiements de santé sont **non tracés** (cash, mobile money non dédié)

2.2 Objectifs

```
graph LR
    A[Diagnostic fiable  
0.5% hallucination] --> D[Vital Ka]
    B[IA sur smartphone  
0 GPU requis] --> D
    C[Païement santé tracé  
Unités Médicales] --> D
    D --> E[Accès aux soins  
panafricain]
    D --> F[Souveraineté IA  
africaine]
```

Objectif	Indicateur	Cible
Fiabilité médicale	Taux d'hallucination	< 1%
Accessibilité	Fonctionnement hors-ligne	100% des fonctions cœur
Souveraineté	Entraînement sur le continent	Kaggle/clouds accessibles
Économie	Wallet UM tracé	0 frais entre proches, AML 5000 UM/mois

3. Architecture globale

3.1 Vue système (déploiement)

```
flowchart TB
    subgraph DEVICE["📱 Appareil (smartphone / PC)"]
        A1["KA Patient"]
        A2["KA Médecin"]
        A3["KA Pharmacien"]
        A4["KA Solidarité"]
        A5["Routeur offline JS"]
    end
    15_hologrammes["15 hologrammes embarqués"]
    end

    subgraph LOCAL["💻 Station / Serveur local"]
        API["API FastAPI :8010"]
        7_endpoints["7 endpoints"]
        ROUTER["Routeur spectral Python"]
        15_domains["15 domaines · 62K faits"]
        MODEL["Modèle 125M (quand entraîné)"]
    end
    end

    subgraph CLOUD["☁️ Kaggle GPU"]
        K["Entraînement HWAT-Med-125M"]
        100K_steps["100K steps · RUNNING"]
    end
    end

    subgraph DATA["📁 Données"]
        D1["medical_holograms/ 8.2 MB"]
        D2["hologram_bundle.json 3.7 MB"]
        D3["tokenizer_medical_50k"]
        D4["medical_corpus/ 63.7 MB"]
    end
    end

    A1 --> A5
    A2 --> A5
    A3 --> A5
    A4 --> A5
    A5 --> API
    API --> ROUTER
    API --> MODEL
    ROUTER --> D1
    D2 --> A5
    MODEL --> K
    K -- ".checkpoints." --> MODEL
    ROUTER --> D3
    ROUTER --> D4
```

3.2 Vue logique — pipeline IA

```
sequenceDiagram
    participant App as Application
    participant Router as Routeur spectral
    participant Facts as Faits médicaux
    participant Phrase as Phrasé naturel

    App->>Router: Requête (symptômes, médicaments...)
    Router->>Router: 1. Couverture lexicale (≥50% mots médicaux ?)
    alt Hors-sujet
        Router-->>App: "Aucune correspondance fiable"
    else Sujet médical
        Router->>Router: 2. Routage top-3 domaines (index lexical)
        Router->>Facts: 3. Retrieval pondéré (sujet 3×, objet 2×)
        Facts-->>Router: Faits + scores normalisés [0,1]
        Router->>Phrase: 4. Template par relation
        Phrase-->>App: Phrases naturelles + seuil 0.15
    end
end
```

3.3 Vue physique — modules

Module	Technologie	Rôle
hwat_torch.py	PyTorch	Architecture HWAT (458 lignes)
train_hwat_kaggle.py	PyTorch	Entraînement 125M (GPU)
train_medical_holograms.py	PyTorch	15 experts médicaux (2.6 min CPU)
hologram_router.py	Python	Routeur spectral + coverage()
inference_server.py	FastAPI	API 7 endpoints
ka_hologram_router.js	JavaScript	Portage offline Android
ka_wallet.js	JavaScript	Wallet UM (crédit/débit/conversion)
launch_app.py	Python HTTP	Serveur frontend web

4. Spécifications fonctionnelles

4.1 Module IA Harmonique

Fonctionnalité	Exigence	Critère d'acceptation
Diagnostic	À partir de symptômes → hypothèses hiérarchisées	Top-3 avec scores, refus si hors-sujet
Prescription	Pathologie + profil patient → posologies	Doses adulte/enfant selon poids
Interactions	Liste de médicaments → paires dangereuses	Sévérité (contreindicated → minor), accents tolérés
Explication	Sujet + public → explication lisible	Phrasé patient vs clinique
Hogrammes	Requête libre → faits des 15 domaines	Routage auto, plantes incluses

4.2 Module Applications

KA Patient

- Dossier médical, médicaments + rappels, constantes, RDV
- Wallet UM : **recevoir** (QR), **envoyer** (frais 0%, AML 5000), **payer soins** (QR prestataire)
- Partage QR (KA Bridge)

KA Médecin

- Diagnostic harmonique enrichi (hogrammes offline)
- Prescription QR → pharmacie
- **Nouveau : Honoraires UM** (encaisser + conversion CFA/EUR)

KA Pharmacien

- Scan ordonnance QR, dispensation
- **Nouveau : Vérification d'interactions** (KA_HOLOGRAM offline)
- Caisse UM + conversion

KA Solidarité (diaspora)

- Achat UM → transfert patient (limite mensuelle)

4.3 Module Portefeuille Santé (UM)

```
flowchart LR
    A["💖 Solidarité"]
    Achat["Achat UM (EUR/CFA)"] --> B["👤 Patient"]
    B --> Wallet["Wallet UM"]
    B --> C["🏪 Pharmacien"]
    B --> D["👨‍⚕️ Médecin"]
    D --> E["🏠 Conversion"]
    E --> CFA["UM → CFA/EUR"]
    C --> E
    B --> F["📦 Envoi entre proches"]
    F --> Frais["frais 0% · AML 5000/mois"]
```

Règle	Valeur
Taux fixe	1 UM = 1 EUR = 655 CFA
Frais entre proches	0%
Limite AML	5000 UM/mois (solidarité)
Conversion prestataire	UM → CFA/EUR (gel des fonds en attente)
Traçabilité	Ledger signé HMAC (1000 tx max)

5. Spécifications techniques

5.1 Architecture HWAT

$$\begin{aligned}\psi_{t,p} &= A_t \cdot e^{i(\varphi_{token,t} + \varphi_{pos,p})} \\ \psi_{t,p} &= A_t \cdot e^{i(\varphi_{token,t} + \varphi_{pos,p})}\end{aligned}$$

Composant	Spécification
Embeddings	Déterministes (FNV-1a, φ -spaced) — 0 octet stocké
Attention	Cohérence de phase $\cos(\varphi_i - \varphi_j) \times \text{amplitude}$
MLP	GELU sur amplitude, phase préservée
LayerNorm	Sur amplitude uniquement
Head	$[\text{Re}(\psi), \text{Im}(\psi)] \rightarrow \text{vocabulaire}$
Déterminisme	Bit-à-bit (zéro dropout)

5.2 Hogrammes médicaux (15 domaines)

Domaine	Faits	PPL	Domaine	Faits	PPL
CLINIQUE	60 000	5.7	MERE_ENFANT	142	17.3
MALADIES	428	10.0	MNT	135	18.5
PHARMACIE	249	13.4	VIH_TB	125	16.7
GENERAL	229	13.6	NUTRITION	106	18.9
URGENCES	188	16.0	PHYTOTHERAPIE	101	14.8
CHRONIQUES	184	14.4	PALUDISME	77	18.9
SANTE_MENTALE	160	14.0	VACCINATION	72	24.1
PEDIATRIE	160	14.2			
TOTAL	62 356 faits	—	Taille	8.2 MB	

5.3 Routing et anti-hallucination

```
flowchart TD
    Q[Requête] --> C{Couverture lexicale
    ≥ 50% mots médicaux ?}
    C -- Non --> R1["Refus : hors-sujet"]
    C -- Oui --> R2{Routage top-3
    index lexical}
    R2 --> S{Meilleur score
    ≥ 0.15 ?}
    S -- Non --> R3["Refus : 'je ne sais pas'"]
    S -- Oui --> R4["Réponse avec phrases + scores"]
```


6. API — Contrats d'interface

6.1 Endpoints

Endpoint	Méthode	Requête	Réponse
/health	GET	—	{status, model_loaded, device}
/model/info	GET	—	{name, parameters, vocab_size...}
/diagnose	POST	{symptoms[], patient_age, history}	{diagnoses[], confidence}
/prescribe	POST	{diagnosis, patient_age, weight, allergies}	{medications[], warnings}
/interactions	POST	{medications[], patient_factors}	{interactions[], severity}
/explain	POST	{topic, audience, language}	{explanation, sources}
/hologram/query	POST	{domain, query, top_k}	{results[], domain}

6.2 Exemple — /diagnose

```
// Requête
POST /diagnose
{
  "symptoms": ["fièvre", "toux", "fatigue"],
  "patient_age": 30,
  "max_diagnoses": 3
}

// Réponse
{
  "diagnoses": [
    {"text": "Le patient présente le symptôme « fièvre_progressive » dans le cadre de Fièvre typhoïde.",
     "score": 0.42, "secteur": "MALADIES"}
  ],
  "confidence": 0.42,
  "disclaimer": "Avertissement: Ceci est une assistance IA, pas un avis médical."
}
```

6.3 Exemple — `/interactions`

```
// Requête
POST /interactions
{ "medications": ["diazépam", "alcool"] }

// Réponse
{
  "interactions": [{
    "pair": ["diazepam + alcool + opiaces", "Dépression respiratoire additive – RISQUE MORTEL"],
    "severity": "contraindicated",
    "mechanism": "Interaction médicamenteuse : diazepam + alcool + opiaces → Dépression respiratoire additive – RISQUE MORTEL"
  }],
  "severity": "contraindicated"
}
```

7. Données

7.1 Corpus médical

Source	Segments	Caractères
14 JSON vital_ka (maladies, paludisme, pédiatrie, pharmacie...)	42 000	18.2M
Cas cliniques réels (real_clinical_dataset)	45 000	28.5M
Q/A synthétiques	45 000	17.0M
Total	132 000	63.7M

7.2 Tokenizer

- BPE, **50 000 tokens**
- Tokens spéciaux : `<icd10>`, `<rx>`, `<dose>`, tags africains (`<wo>`, `<bm>` ...)

7.3 Bundle offline Android

Fichier	Taille	Contenu
<code>hologram_bundle.json</code>	3.7 MB	15 domaines, 62 356 faits, vocabulaire, templates

8. Sécurité et conformité

```
flowchart LR
    A[Chiffrement AES-GCM  
dossiers] --> D[Applications]
    B[QR signés HMAC  
transferts] --> D
    C[PIN obligatoire  
verrouillage] --> D
    D --> E[Anonymisation  
k-anonymity]
    D --> F[Ledger UM  
auditable]
```

Menace	Protection
Hallucination médicale	Seuil 0.15 + couverture lexicale + refus explicite
Fraude wallet	Limite AML 5000/mois, ledger signé, PIN
Interception transfert	QR HMAC, chiffrement AES-GCM
Données patients	100% local (localStorage), anonymisation
Accès non autorisé	PIN + verrouillage automatique

9. Performance

Métrique	Cible	Mesuré
Latence <code>/hologram/query</code>	< 100 ms	3 ms (médiane)
Routage clinique	> 90%	10/10 (100%)
Pièges bloqués	100%	3/3 + couverture lexicale
Taille bundle offline	< 5 MB	3.7 MB
Chargement routeur JS	< 1 s	~0.5 s
Mémoire serveur	< 1 GB	~200 MB

10. Déploiement

10.1 Topologie

Environnement	Services	Ports
Station locale	API + frontend	8010 + 8080
Android (APK Capacitor)	Tout embarqué (offline)	—
Cloud (future)	API + 125M + monitoring	80/443

10.2 Pipeline de build Android

```
flowchart LR
    S["engine/ (source de vérité)"] --> SYNC["sync-assets.mjs"]
    B["build_hologram_bundle.py"] --> BUNDLE["hologram_bundle.json"]
    BUNDLE --> SYNC
    SYNC --> WWW["www/ (Capacitor)"]
    WWW --> APK["npx cap sync android → APK"]
```

⚠ **Règle d'or** : toute modification se fait dans `engine/`, puis `node scripts/sync-assets.mjs`. `www/` est régénéré (ignoré par git).

11. Planification et budget

11.1 Jalons

Jalon	État	Date
S1 — Phase 1 (NPZ→PT)	✓	Juillet 2026
S2 — Corpus + tokenizer	✓	Août 2026
S3 — Hologrammes médicaux	✓	Août 2026
S4 — API 7 endpoints	✓	Août 2026
S5 — Apps complètes (wallet, interactions)	✓	Août 2026
S6 — Entraînement 125M	● EN COURS	Kaggle GPU
S7 — SFT + alignement	⌚	Après S6
S8 — LoRA 12 spécialités	⌚	Après S7
S9 — Production + monitoring	⌚	T4 2026

11.2 Budget

Poste	Coût
Phase 1-3 (déjà réalisées)	~\$25-35K
GPU 125M (Kaggle gratuit + complément)	\$0-400
Production (2× serveur)	\$300-600/mois
Total vers production	\$25-70K

12. Risques et mitigations

Risque	Prob.	Impact	Mitigation
Corpus 63.7M trop petit pour fluence	Moyenne	Élevé	Hologrammes (voie A) déjà opérationnels, 125M en bonus
Hallucination résiduelle	Faible	Critique	Seuil + couverture + refus explicite + validation médecins
GPU indisponible	Moyenne	Moyen	Kaggle 30h/sem, RunPod, partenariat MTN
Adoption soignants	Moyenne	Moyen	Co-design, valeur immédiate (gain de temps)
RGPD / données	Faible	Élevé	100% local, anonymisation, consentement

13. Critères de validation

Critère	Test	Résultat attendu
Routage clinique	10 requêtes types	≥ 9/10 corrects
Anti-hallucination	Hors-sujets (football, gâteau)	100% bloqués
Interactions	diazépam+alcool, metronidazole+alcool	contreindicated
Wallet	Crédit → envoi → paiement → conversion	Flux complet sans perte
Offline	APK sans réseau	Diagnostic + interactions + wallet OK
Latence	20 requêtes	Médiane < 20 ms

14. Annexes

Document	Lien
Plan d'implémentation session	PLAN_IMPLEMENTATION_SESSION.md
Roadmap 3 phases	ROADMAP_HARMONIC_TRANSFORMER_VITAL_KA.md
Dossier MTN	dossier_mtn/
Guide Android	vital-ka-android/GUIDE_ANDROID.md
Doc fondateur HWAT	DOCUMENT_FONDATEUR_HWAT.md

Cahier des charges v2.0 — Vital Ka × HWAT — 2026-08-01